VLA はなぜ掴めないのか

実機 SO-101 で原因を一つずつ切り分け、言葉で頼める片付けロボットにした記録

Physical AI 講座 2026 応用編1 最終課題 ・ 動画: (公開後に追記) ・ コード: https://github.com/142291/pai-final-vla-tidybot

自分で録画した手本で π0.5 をファインチューンし、机の上の 3 色のキューブを箱へ片付けさせた。学習は順調に見えたのに、実機では**キューブのすぐ上まで行って掴めない**。この「なぜ」を、記録したデータと対照実験で一つずつ切り分けた。

見つかった原因は 3 つ。**① 推論の遅延の間に、外れやすい予測の後半を実行していた、② 学習データに無い状況(箱にキューブが入った状態)では動かない、③ 学習が足りていなかった(可能性が高い)**。逆に、**人の手助けを学習に戻す効果は、対照実験では確認できなかった**。最後に、言葉の指示(Claude)、成否の判定、やり直し、失敗の説明、人への引き継ぎをつないで、「片付けて」と頼めるロボットにした。

33% → 80%
同じモデル・同じ 15 配置(5 か所 × 3 色)・同じ晩に、実行の仕方だけを変えた成功率(標準の非同期 → 止まって考える)。別の晩は 93%

53% → 93%
同じ 15 配置での成功率(どちらも止まって考える実行)。データの穴を埋め、学習を延ばした結果(最初のモデル → 最良のモデル)

15 / 24
通し動作「片付けて」で、人の手を借りずに箱へ入った色の数。残りは失敗の説明 → 人を呼ぶ → 引き取りで、最終的に 24/24

1. 作ったもの

机の上の赤・黄・紫のキューブを、言葉の指示で箱へ片付ける実機ロボット。System 2 / System 1 の 2 段構えにした。

```
「紫以外を片付けて」 ➡ 段取り(Claude が俯瞰画像を見て色の順番を決める。無い色・できない指示は断る)
                                        | 1 色ずつ
                                        ▼
        π0.5(自前データでファインチューン。H200 で推論、Mac でアームを動かす。止まって考える実行)
                                        |
        俯瞰カメラで判定(箱の中で 1 秒止まったら成功) ── 成功 ➡ ホームへ戻って次の色
                                        | 失敗
        何が起きたかを Claude が画像で説明して読み上げ ➡ ホームへ戻ってやり直し(最大 3 回)
                                        | 3 回とも失敗
        声で人を呼ぶ ➡ 人がリーダーアームで引き取る(その動きは学習データとして保存)
```

講座のサンプル	この作品で加えたこと
SO-101 入門(テレオペ・録画・学習)	3 照明 × 3 色の録画手順、1 本ずつの監査ツール、置き場所の偏りの分析、π0.5 のファインチューン(H200)、置き場所を画面に示して毎回同じ配置で比べる評価ツール
自然言語でロボット操作	言葉 → 色の列(構造化出力で検証)→ 学習済みの指示文、の 2 段構え。画像で卓上の状態を確かめ、無い色や箱の中の色は除く
VLM でロボットを動かす	成否の判定(キューブは色検出、それ以外は Claude)、失敗の説明、やり直しと人への引き継ぎ
(サンプルに無い)	遅延の原因を「予測と人の操作の比較」で突き止め、止まって考える実行で解決。データの穴と学習不足を対照実験で切り分け

2. 実機とデータ

- **アーム**: SO-101(フォロワー + リーダー)。カメラは俯瞰と手首の 2 台(640×360、30fps)。
- **計算**: アームの制御は Mac、学習と推論はクラウドの H200。観測を JPEG にして送り、行動のまとまり(action chunk、50 ステップ = 1.7 秒分)を受け取る。推論そのものは約 0.36 秒で、残りは通信・画像の符号化・待ち合わせ。観測から行動が届くまで約 0.9〜1.3 秒。
- **方策**: π0.5(PaliGemma ベースの VLA)を自前データでファインチューン。比較用に SmolVLA と ACT も同じデータで学習。
- **手本**: 3 色 × 50 本 × 照明 3 条件(朝・昼・夜)の 150 本を、リーダーアームで録画。全本を目視で確認して 144 本を学習に使用。
- **追加**: 評価で見つけたすき間(アームの真下の中央、手前の端)と、「箱に他の色が入った状態から」の手本 45 本。置き場所を画面の丸と声で案内する録画ツールで撮った。
- **評価**: 3 色 × 5 か所 = 15 配置を固定の順で 1 回ずつ。試行の前に俯瞰映像へ置き場所の丸を出し、毎回同じ配置で比べる。成否は作者が見てキーで記録(60 秒以内に箱へ入れば成功)。成功率には Wilson の 95% 信頼区間を付ける。以下「15 配置」はこの評価を指す。

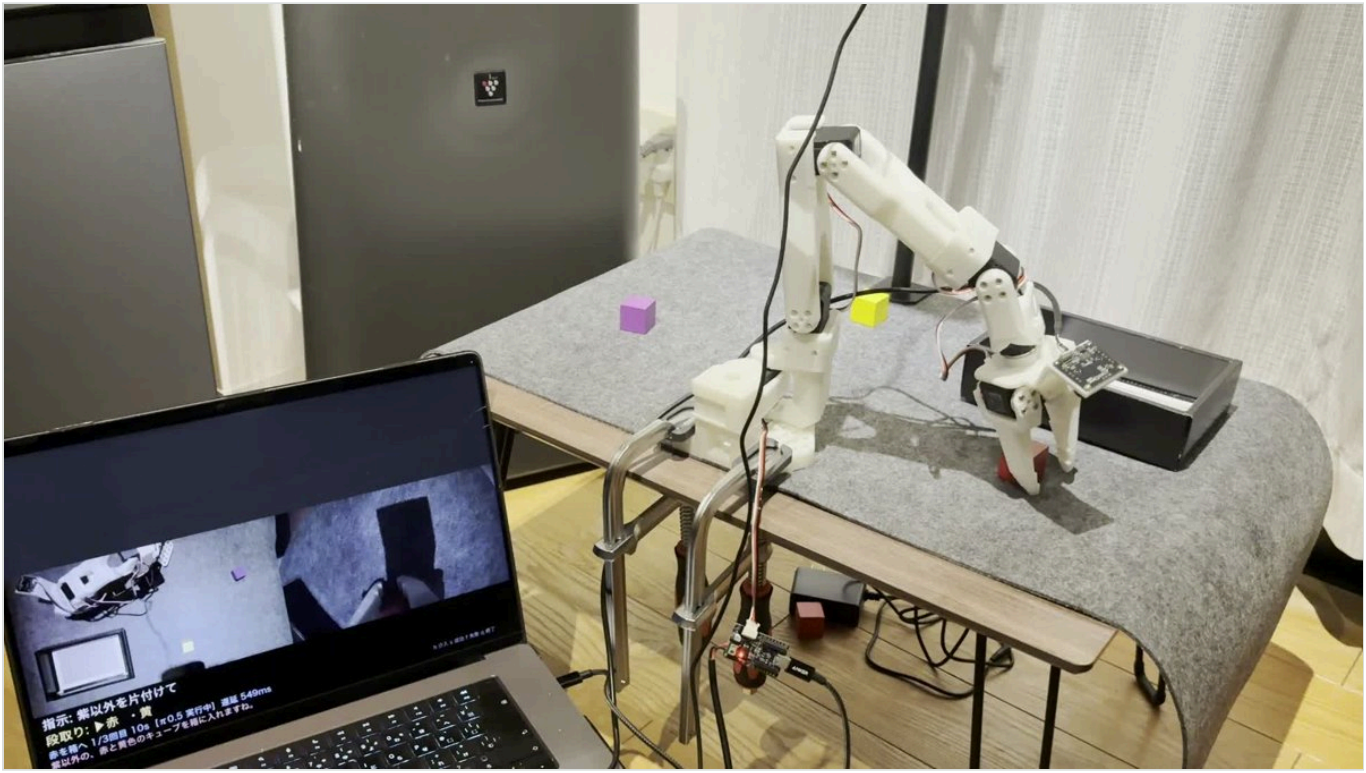


写真 1. 実機。手前の画面は、指示・段取り・試行回数・遅延・ロボットの発話を表示する(動画にも使用)。俯瞰カメラはアームの上、手首カメラはグリッパに付いている。

3. 謎 1: すぐ上まで行くのに掴めない

最初のモデルは 15 試行で 6 回(40%)しか成功しなかった。失敗はほとんどが「キューブのすぐ上まで来て、少しずれた所で掴もうとし続ける」型だった。手でキューブを顎の間に置いてやれば掴める。

測ったこと: 予測は先のステップほど外れる

学習に使っていない 4 本の手本で、モデルの予測と人の実際の操作を比べた。行動のまとまり(50 ステップ = 1.7 秒分)の先頭 0〜5 ステップ目の誤差は 3.3 だが、35〜50 ステップ目は 13.1。学習データ上ではどこも 1.5〜2.4 で平らなので、未知の場面では「先の予測ほど当てにならない」。SmolVLA・ACT でも同じ傾向だった。

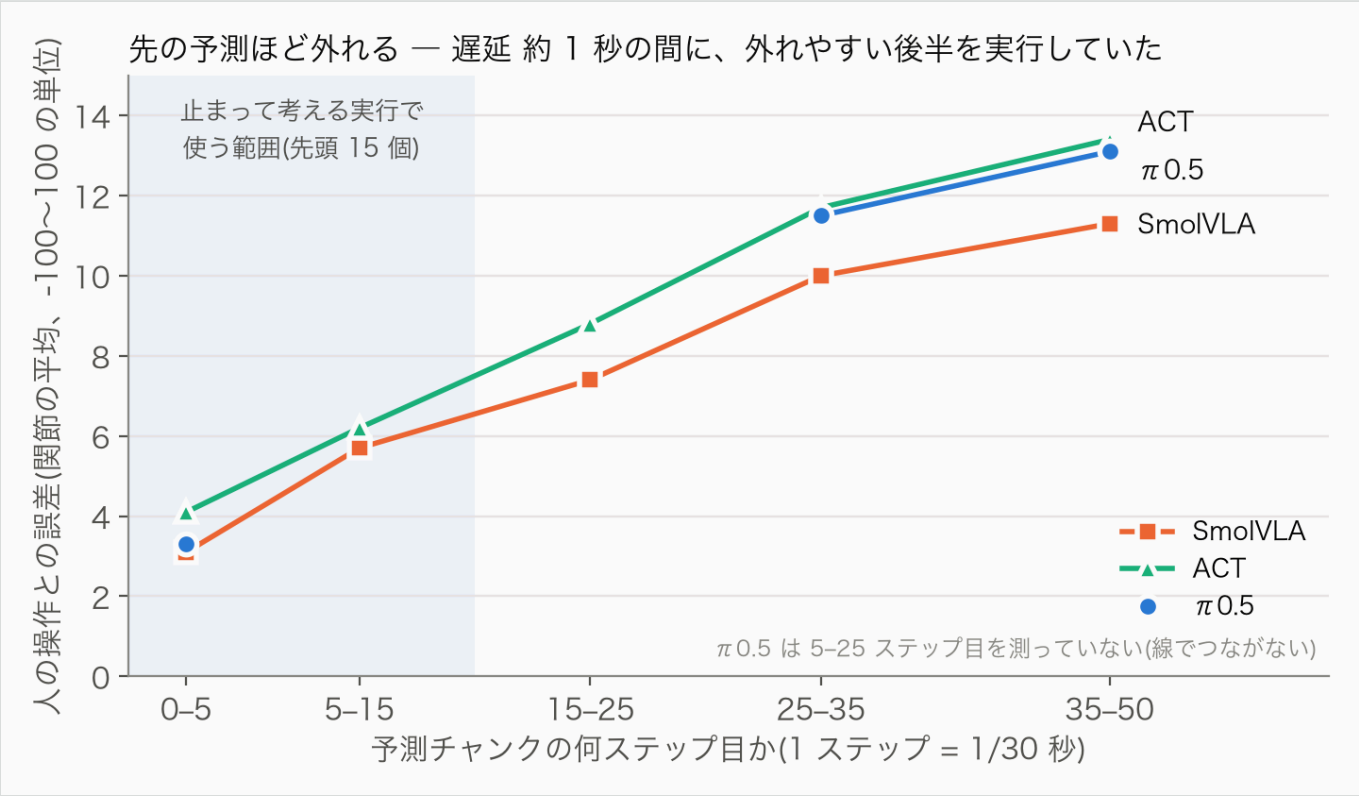


図 1. 予測の何ステップ先かと、人の操作との誤差(学習に使っていない 4 本、動いている区間)。網掛けは止まって考える実行で使う範囲。

最有力の原因: 遅延の間に、外れやすい後半を実行していた

観測から行動が届くまでに約 1 秒(30 ステップ分)かかる。標準の非同期実行は、届いた時点で過ぎてしまった前半を飛ばし、**外れやすい後半**を実行していた。さらに古いまとまりと新しいまとまりを混ぜていた。土台を大きく回す横の位置ほど、この 1 秒のずれが効く。

対策: 止まって考える実行

まとまりの先頭 15 ステップ(0.5 秒、実行ホライズン K = 15 の同期実行)だけを実行して止まり、**止まった後の画像**で次のまとまりを予測させる。止まった時刻より前の観測にもとづくまとまりは捨てる。動きは途切れるが、常に予測のいちばん正確な部分だけを使う。LeRobot の非同期推論のクライアントを継承して実装した(`scripts/remote/fast_client.py`)。

同じモデル(最良)・同じ 15 配置	成功	メモ
標準の非同期実行	5/15 = 33% [15–58%]	10/31 夜
止まって考える実行(先頭 15 ステップ)	**12/15 = 80% [55–93%]**	10/31 夜(非同期と同じ晩)。配置ごとに比べると、止まって考えるだけ成功 9、非同期だけ成功 2(正確な McNemar 検定 p = 0.065)
止まって考える実行(別の晩)	**14/15 = 93% [70–99%]**	10/28 夜。配置ごとに比べると 9 対 0(p = 0.004)。ただし非同期とは晩が違う

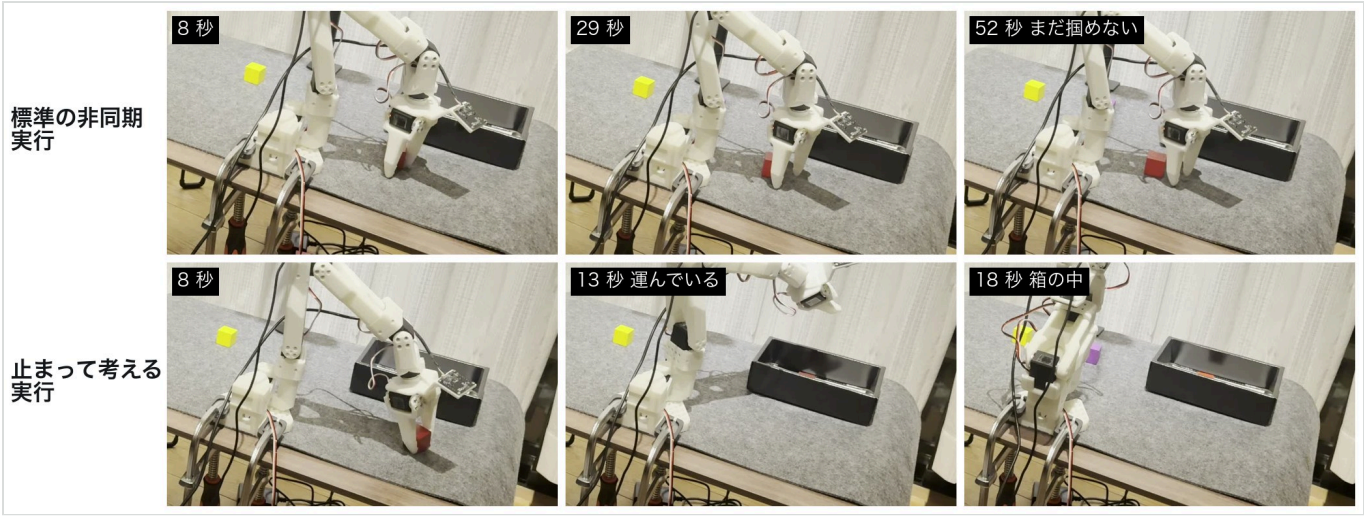


写真 2. 同じモデル・同じ置き場所で、実行の仕方だけを変えて続けて動かした(11/1、動画 0:03〜)。秒は指示からの経過時間。非同期は 60 秒で時間切れ、止まって考える実行は 1 回目で箱へ入った。

切り分けきれていないこと: 止まって考える実行は、前半を捨てること以外にも、新旧のまとまりを混ぜない、止まってから画像を撮る(動きのぶれが無い)という点で非同期と違う。どれが効いたかまでは分けていない。K = 15 以外の値や、非同期側の設定(切り替えのしきい値、混ぜ方)も 1 通りしか試していない。

4. 謎 2: 1 個入ると、次が動かない

「片付けて」で通して動かすと、1 個目が箱に入った後、2 個目に取りかからずその場で止まった。学習データ 144 本を調べると、**箱にキューブが入った状態から始まる手本は 0 本**だった。実際に止まった場面の観測(画像と関節角)を記録から取り出し、モデルに見せて「どれだけ動こうとするか」を測った(`scripts/remote/replay_probe.py`)。

記録した場面	最初のモデル	「箱に入った状態から」の手本 45 本を足したモデル
赤が箱の中、黄を指示(実機で止まった場面)	1.6(動かない)	120.8
同上、別の場面	1.5(動かない)	106.4
箱が空、赤を指示(実機で動いた場面)	106.1	110.9

値は、予測した 50 ステップの中で、今の姿勢から最も離れる関節の離れ幅(グリッパを除く 5 関節。関節は -100〜100 に正規化した単位なので、差は最大 200。3 回の平均)。足りない状況の手本を足すと、その状況で動くようになることが、実機を動かさずに確かめられた。

5. 学び直しは本当に効いたのか(対照実験)

データを足して学び直すたびに、同じ 15 配置での成功率は 53% → 67% → 80% と上がった。人が通し動作で手伝った区間(リーダーアームで引き取った動き)を学習に戻したのがラウンド 2 と 3。ところが、**ラウンド 1 のデータのまま学習を同じだけ延ばした対照モデル**が 93% で最も高かった。ただし 67%(10/15)と 93%(14/15)の差は、15 試行では統計的に言い切れない。

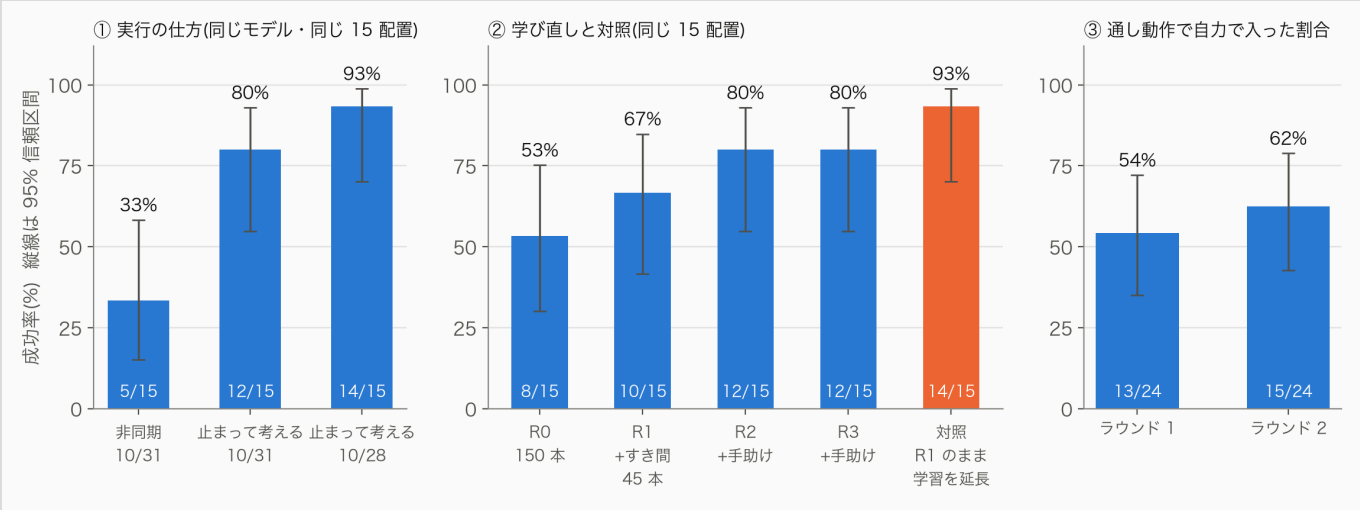


図 2. 左: 実行の仕方だけを変えた比較(最良のモデル、同じ 15 配置)。中: 同じ 15 配置での成功率。オレンジが対照。右: 通し動作で人の手を借りずに箱へ入った割合。縦線は 95% 信頼区間。

モデル	学習データ	追加の学習	成功
ラウンド 0	手本 144 本	20,000 step	8/15 = 53%
ラウンド 1	+ すき間・箱に入った状態から 45 本	+6,000	10/15 = 67%
ラウンド 2	+ 人の手助け 11 区間 ×3	+4,000	12/15 = 80%
ラウンド 3	+ 人の手助け 8 区間 ×3	+4,000	12/15 = 80%
対照	ラウンド 1 と同じ(手助けなし)	+4,000	**14/15 = 93%**

- **人の手助けデータの効果は確認できなかった。**ラウンド 1 → 2 の伸びは、学習を延ばした効果で説明できる。手助けの区間は失敗した途中の姿勢から始まり、急な動きや止まった時間を含み、量も 2.7 分と少なかった。3 倍の重みで偏らせた可能性がある。
- **15 試行の比較は揺れが大きい。**ラウンド 2 と 3 は成功数が同じなのに、失敗した配置が 3 つとも入れ替わった。配置 1 つを取り出して「直った」とは言わない。
- 確かに言えるのは、**足りない状況のデータを足すと、その状況で動くようになる**(4 章)ことと、**学習が足りないと伸びない**こと。

6. 「片付けて」と頼めるようにする

段取り(System 2)

Claude に俯瞰画像と指示を渡し、構造化出力で色の列を返させる。π0.5 には学習時とまったく同じ英語の指示文だけを渡す。Claude が使えないときはキーワードのルールに切り替える。

指示	段取り	ロボットの返事
片付けて	赤 → 紫 → 黄	箱に近い順に片付けます
紫以外を片付けて	赤 → 黄	赤と黄色を箱に入れますね
信号の色のものだけ箱に入れて	赤 → 黄	信号の色の赤と黄色を箱に入れますね
緑のを入れて	(なし)	緑のキューブは見当たらないので入れられません

判定・やり直し・失敗の説明・人への引き継ぎ

- **判定**: 俯瞰カメラで、対象の色が箱の領域で 1 秒止まったら成功(運んでいる途中は動くので除ける)。色で見つけられない物は、Claude に画像で判定させる(記録した 4 枚で 4 枚とも正しかった)。
- **失敗の説明**: 失敗した試行の画像 5 組を Claude に見せ、「赤のすぐ上まで来ましたが、掴めませんでした」のように一人称で読み上げる。評価の失敗 8 回を作者が録画で分類した型と比べると、型の一致は 4/8。外れた回も「押し出した後に見失った」のように隣り合う型で、説明は録画と食い違わなかった。
- **人への引き継ぎ**: 3 回失敗すると声で人を呼ぶ。人がリーダーアームをフォロワーと同じ姿勢にして h を押すと、その場から操作を引き取れる。操作は学習データと同じ形式で保存する。

通し動作の結果

「片付けて」を 8 回ずつ(24 色)通した。最終的に箱へ入ったのはどちらも 24/24。人の手を借りずに入ったのは、ラウンド 1 が 13/24 = 54%、ラウンド 2 が 15/24 = 62%。人の手助けが要ったのは主に、2 色目の黄(箱に赤が入った状態から)と、手前・右の端だった。動画の撮影(10/31〜11/1)では撮り直しのために途中で止めた回が多いので、成功率には数えていない。動画に使った回は、「紫以外を片付けて」が 2 色とも自力、「片付けて」が 3 色とも自力、苦手な真ん中に置いた「赤だけ入れて」は 3 回失敗して説明 → 人を呼んで引き取り。同じ置き場所で実行の仕方だけを変えて続けて動かすと、非同期は 60 秒たっても掴めず、止まって考える実行は 16 秒で箱へ入った(動画 0:03〜)。

7. 開発中に見つけた問題と対策

問題	突き止め方	対策
近くまで行くが掴めない	予測と人の操作の比較。先の予測ほど外れ、遅延の間に後半を実行していた	止まって考える実行
制御ループが 1 周 3.5〜4.3 秒	区間ごとの計測。生画像 1.38MB を同期で送っていた	送信を裏スレッドへ、JPEG で送る(1 周 2〜4ms)
推論が倍に遅い	GPU の使用状況。別のシミュレータ 2 つが計算を占有していた	止めて 520 → 255ms
箱が数 cm ずれていた	学習時の画像と重ねて比較(箱だけ約 53px ずれ)	重ね合わせツールで毎回確認
夜に箱を誤検出	学習 150 本で検出を確かめ直し、夜の 50 本すべてで誤っていた	彩度と形で床を除く
1 個入ると次が動かない	学習データの開始時の状態を調べたら 0 本。記録した場面の再生で確認	「箱に入った状態から」の手本
失敗が置き場所に偏る	評価の初期位置を学習データの置き場所に重ねた(3 つのかたまりに偏り)	すき間を狙った追加録画
モデルの差と置き場所の差が混ざる	同じ晩に前のモデルも成績が落ちていた	置き場所を映像に丸で示す評価ツール
人の手助けで伸びたように見えた	手助けを抜いて同じだけ学習した対照モデル	伸びは学習不足の解消と判明(5 章)
手助けの判定が「入っていない」	録画を確認。手伝いの途中で俯瞰カメラにぶつかり画像が約 90px ずれていた	その区間を学習から除外
データの結合後に読み込めない	LeRobot の結合ツールが、元データのファイル番号を目次にそのまま写していた	目次を直して結合(不具合として報告予定)

8. 限界と今後

- **試行数**: 1 条件 15 試行で、信頼区間が広い。15 試行の中の 1 配置ごとの成否は揺れる。
- **評価者・環境**: 評価者は作者 1 人、1 台、1 つの机。夜の照明での評価が中心。
- **速さ**: 止まって考える実行は 1 色 20〜45 秒。遅延の短縮や、遅延を見込んだ予測(Real-Time Chunking など)と組み合わせるのが次の課題。
- **学習に無い物**: 自前データで微調整した π0.5 が、学習に無い物(例えば消しゴム)をどこまで扱えるかは確かめきれていない。消しゴムで 1 回試しただけで、評価と言える数は無い。段取り役は「教わっていない物」を区別して人に頼むようにしてある。
- **人の手助けの学び直し**: 今回は効果を確認できなかった。失敗した姿勢からの区間の整え方、重み、量を変えて確かめたい(HG-DAgger などの対話的な模倣学習の考え方)。

9. 再現方法・生成 AI の利用・ライセンス

セットアップ、録画、学習、評価、通し動作のコマンドはリポジトリの README にまとめた。評価の結果は `outputs/eval/results.csv`(試行ごと)と `docs/evaluation.md`(経緯)に残している。開発では Claude(Claude Code)をコードの作成、録画の分析、文書の下書きに使い、すべての判断と実機の作業は作者が行った。ロボットの段取り・判定・失敗の説明には Claude API を使う。コードは MIT ライセンス。π0.5 の重みは openpi / LeRobot の条件に従い、公開しない。